

Problem Set 3

1 Lagrange Duality

Formulate the Lagrange dual problem of the following linear programming problem

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \preceq b \end{aligned}$$

where $x \in \mathbb{R}^n$ is variable, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{k \times n}$, $b \in \mathbb{R}^k$.

由题意，引进拉格朗日函数，得：

$$\mathcal{L}(x, \alpha) = c^T x + \alpha^T (Ax - b)$$

其中， α 为拉格朗日乘子，满足： $\alpha \geq 0$ 。

构建拉格朗日对偶问题函数：

$$\begin{aligned} \mathcal{G}(\alpha) &= \inf_x \mathcal{L}(x, \alpha) \\ &= \inf_x (c^T x + \alpha^T (Ax - b)) \\ &= \inf_x ((c^T + \alpha^T A)x - \alpha^T b) \end{aligned}$$

若 $c^T + \alpha^T A$ 不为0，则 x 为 $+\infty$ 或 $-\infty$ ，显然不合适，

因此： $c^T + \alpha^T A = 0$ ，对偶问题函数变为：

$$\begin{aligned} \mathcal{G}(\alpha) &= \inf_x (-\alpha^T b) \\ &= -\alpha^T b \end{aligned}$$

再极大化对偶问题函数：

$$\max_{\alpha} \mathcal{G}(\alpha) = \max_{\alpha} (-\alpha^T b)$$

综合之前提到的约束条件，得到题目中对应的拉格朗日对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & (-\alpha^T b) \\ \text{s.t.} \quad & \alpha \geq 0 \\ & c^T + \alpha^T A = 0 \end{aligned}$$

2 SVM

2.1 Convex Functions

Prove $f(\omega) = \omega^T \omega$ (where $\omega \in \mathbb{R}^n$) is a convex function.

由于 $\omega \in \mathbb{R}^n$ ，不妨假定：

$$\omega = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

则：

$$f(\omega) = \omega^T \omega = x_1^2 + x_2^2 + \cdots + x_n^2$$

要证明 $g(x)$ 为凸函数，即证明：

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2)$$

令 $g(x) = x^2$ ，有：

$$f(\omega) = g(x_1) + g(x_2) + \cdots + g(x_n)$$

下面通过数学归纳法证明 $f(\omega)$ 为凸函数：

当 $n = 1$ 时，显然满足凸函数定义，即 $g(x) = x^2$ 为凸函数。

当 $n > 1$ 时，令 $\mathcal{G}(x) = g_1(x) + g_2(x)$ ，其中 $g_1(x)$ 、 $g_2(x)$ 均为凸函数，有：

$$\begin{aligned} \mathcal{G}(\lambda x_1 + (1 - \lambda)x_2) &= g_1(\lambda x_1 + (1 - \lambda)x_2) + g_2(\lambda x_1 + (1 - \lambda)x_2) \\ &\leq \lambda g_1(x_1) + (1 - \lambda)g_1(x_2) + \lambda g_2(x_1) + (1 - \lambda)g_2(x_2) \\ &= \lambda(g_1(x_1) + g_2(x_1)) + (1 - \lambda)(g_1(x_2) + g_2(x_2)) \\ &= \lambda \mathcal{G}(x_1) + (1 - \lambda)\mathcal{G}(x_2) \end{aligned}$$

因此，两个凸函数相加得到的函数仍为凸函数，故 $n > 1$ 时， $f(\omega)$ 仍为凸函数。

得证： $f(\omega) = \omega^T \omega$ 为凸函数。

2.2 Soft-Margin for Separable Data

Consider training a soft-margin SVM with C set to some positive constant. Suppose the training data is linearly separable. Since increasing the ξ_i can only increase the objective of the primal problem, all the training examples will have functional margin at least 1 and all the ξ_i will be equal to zero. True or false? Explain! Given a linearly separable dataset, is it necessarily better to use a hard margin SVM over a soft-margin SVM?

对于软间隔SVM，其约束条件为：

$$y^{(i)}(\omega^T x^{(i)} + b) \geq 1 - \xi_i$$

其中， ξ_i 为松弛变量。

相应的优化问题为：

$$\begin{aligned} \min_{\omega, b, \xi} \quad & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y^{(i)}(\omega^T x^{(i)} + b) \geq 1 - \xi_i, \quad \forall i = 1, \dots, m \\ & \xi_i \geq 0, \quad \forall i = 1, \dots, m \end{aligned}$$

对应的拉格朗日对偶问题：

$$\mathcal{L}(\omega, b, \xi, \alpha, r) = \frac{1}{2} \omega^T \omega + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y^{(i)}(\omega^T x^{(i)} + b) - 1 + \xi_i] - \sum_{i=1}^m r_i \xi_i$$

其中, α_i 为拉格朗日乘子, 满足: $\alpha_i \geq 0, \text{ for } \forall i$ 。

依据KKT条件, 有:

$$\begin{aligned}\nabla_{\omega} \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \omega^* = \sum_{i=1}^m \alpha_i^* y^{(i)} x^{(i)} \\ \nabla_b \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \sum_{i=1}^m \alpha_i^* y^{(i)} = 0 \\ \nabla_{\xi_i} \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \alpha_i^* + r_i^* = C, \text{ for } \forall i \\ \alpha_i^*, r_i^*, \xi_i^* &\geq 0, \text{ for } \forall i \\ y^{(i)}(\omega^{*T} x^{(i)} + b^*) + \xi_i^* - 1 &\geq 0, \text{ for } \forall i \\ \alpha_i^*(y^{(i)}(\omega^{*T} x^{(i)} + b^*) + \xi_i^* - 1) &= 0, \text{ for } \forall i \\ r_i^* \xi_i^* &= 0, \text{ for } \forall i\end{aligned}$$

可推导出:

$$\alpha_i, r_i \geq 0, \alpha_i + r_i = C \Rightarrow 0 \leq \alpha_i, r_i \leq C$$

当 $\alpha_i = 0$ 时, 有:

$$\begin{aligned}\alpha_i = 0, \alpha_i + r_i = C &\Rightarrow r_i = C \\ r_i = C, \xi_i \geq 0, r_i \xi_i = 0 &\Rightarrow \xi_i = 0 \\ \xi_i = 0, y^{(i)}(\omega^T x^{(i)} + b) \geq 1 - \xi_i &\Rightarrow y^{(i)}(\omega^T x^{(i)} + b) \geq 1\end{aligned}$$

此时, 对应的训练样本不是支持向量, 不会对该SVM边界的确定产生任何影响。

当 $0 < \alpha_i < C$ 时, 有:

$$\begin{aligned}0 < \alpha_i < C, \alpha_i + r_i = C &\Rightarrow r_i \neq 0 \\ r_i \neq 0, r_i \xi_i = 0 &\Rightarrow \xi_i = 0 \\ \alpha_i(y^{(i)}(\omega^T x^{(i)} + b) + \xi_i - 1) = 0, \alpha_i > 0 &\Rightarrow y^{(i)}(\omega^T x^{(i)} + b) + \xi_i - 1 = 0 \\ &\Rightarrow y^{(i)}(\omega^T x^{(i)} + b) = 1 - \xi_i \\ &\Rightarrow y^{(i)}(\omega^T x^{(i)} + b) = 1\end{aligned}$$

此时, 对应的训练样本为支持向量, 恰好在最大间隔边界上。

当 $\alpha_i = C$ 时, 对应的训练样本落在最大间隔内部或被误分类, 由于题目中已告知该数据集为线性可分的, 因此不存在该种情况。

综合 $\alpha_i = 0$ 及 $0 < \alpha_i < C$ 的两种情况, 可知在该线性可分数据集上, 满足:

$$\begin{aligned}y^{(i)}(\omega^T x^{(i)} + b) &\geq 1 \\ \xi_i &= 0, \forall i = 0\end{aligned}$$

而对于任意一个线性可分数据集, 使用软间隔SVM的效果是要优于硬间隔SVM的。

假设线性可分的两类样本A、B之间间隔很远, 但有一个A类样本十分接近B类样本所在的区域, 此时若仍使用硬间隔SVM进行分类, 算法会选择这一个接近B样本区域的A样本作为支持向量, 此时, 尽管仍能对两类样本进行分类, 但分类边界会大大偏向于B类样本, 出现出过拟合的现象。

2.3 In-bound Support Vectors in Soft-Margin SVMs

Examples $x^{(i)}$ with $\alpha_i > 0$ are called support vectors (SVs). For soft-margin SVM we distinguish between *in-bound* SVs, for which $0 < \alpha_i < C$, and *bound* SVs for which $\alpha_i = C$. Show that in-bound SVs lie exactly on the margin. Argue that bound SVs can lie both on or in the margin, and that they will "usually" lie in the margin. Hint: use the KKT conditions.

由上题可知, 当 $0 < \alpha_i < C$, 即该点为 *in-bound* SV 时:

$$y^{(i)}(\omega^T x^{(i)} + b) = 1$$

因此, *in-bound* SV 在 margin 上。

而当 $\alpha_i = C$, 即该点为 *bound* SV 时:

由 KKT 条件:

$$\begin{aligned}\nabla_{\omega} \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \omega^* = \sum_{i=1}^m \alpha_i^* y^{(i)} x^{(i)} \\ \nabla_b \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \sum_{i=1}^m \alpha_i^* y^{(i)} = 0 \\ \nabla_{\xi_i} \mathcal{L}(\omega^*, b^*, \xi^*, \alpha^*, r^*) &= 0 \Rightarrow \alpha_i^* + r_i^* = C, \text{ for } \forall i \\ \alpha_i^*, r_i^*, \xi_i^* &\geq 0, \text{ for } \forall i \\ y^{(i)}(\omega^{*T} x^{(i)} + b^*) + \xi_i^* - 1 &\geq 0, \text{ for } \forall i \\ \alpha_i^* (y^{(i)}(\omega^{*T} x^{(i)} + b^*) + \xi_i^* - 1) &= 0, \text{ for } \forall i \\ r_i^* \xi_i^* &= 0, \text{ for } \forall i\end{aligned}$$

可得:

$$\alpha_i = C, \alpha_i + r_i = C \Rightarrow r_i = 0$$

由于 $r_i = 0$, $r_i \xi_i = 0$, $\xi_i \geq 0$, 且除此之外没有其他关于 ξ_i 的限制条件, 因此:

$$\xi_i \geq 0:$$

得到:

$$y^{(i)}(\omega^T x^{(i)} + b) = 1 - \xi_i \leq 1$$

当上式等于1, 即仅当 $\xi_i = 0$ 时, 该样本点位于 margin 上, 而当上式小于1, 即 $\xi_i > 0$ 时, 该样本点位于 margin 内, 因此大多数情况下满足位于 margin 内的情况。

因此, *bound* SV 位于 margin 上或 margin 内, 且大多位于 margin 内。